Note de cadrage — Projet P05 : analyse distribuée des avis clients et des tendances

Objet

Cette note fixe les données, les choix et les risques de départ du projet P05, avant la préparation et les jobs MapReduce.

Le projet construit une chaîne distribuée qui identifie les termes caractéristiques des avis de chaque produit et suit l'évolution mensuelle des notes. Le corpus est la catégorie *Appliances* d'Amazon Reviews'23. Les calculs sont faits par trois jobs Java Hadoop MapReduce, et les résultats sont publiés dans des tables Apache Iceberg (architecture Lakehouse).

Mariem Bibi & Mohamed Lassoued

Source et provenance

Le corpus est le fichier officiel *Appliances* d'Amazon Reviews'23, téléchargé le 01/11/2026 et archivé sans modification en zone bronze.

Élément	Valeur
Jeu de données	Amazon Reviews'23, catégorie *Appliances*
Producteur	McAuley Lab, UC San Diego
Portail officiel	amazon-reviews-2023.github.io
Fichier téléchargé	Appliances.jsonl.gz
Date de téléchargement	01/11/2026
Format	JSON Lines compressé (gzip), un avis par ligne
Taille du fichier	[à compléter : champ taille_octets de profil_dataset.json]
Empreinte SHA-256	[à compléter : champ sha256 de profil_dataset.json]
Référence scientifique	Hou et al., *Bridging Language and Items for Retrieval and Recommendation*, 2024, arXiv:2403.03952

Élément	Valeur
Conditions d'usage	Usage pédagogique ; pas de redistribution du fichier ; `user_id` jamais affiché ni exporté

Champs observés et champs retenus

Le fichier contient 10 champs ; le projet en retient 5 pour les calculs.

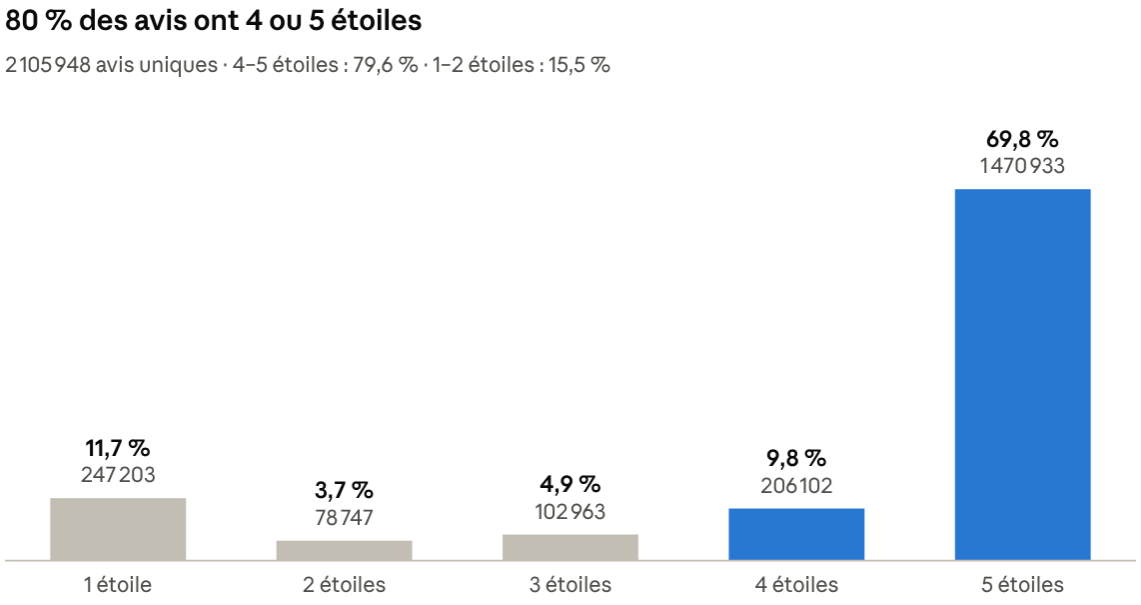
Champ	Signification	Décision
`parent_asin`	Identifiant de regroupement du produit	Retenu : clé produit principale
`rating`	Note de 1 à 5	Retenu : entrée de MR3
`timestamp`	Date de l'avis, en millisecondes	Retenu : converti en mois AAAA-MM (UTC)
`title`	Titre de l'avis	Retenu : texte analysé, avec `text`
`text`	Corps de l'avis	Retenu : texte analysé
`user_id`	Identifiant de l'auteur (sensible)	Utilisé uniquement pour détecter les doublons ; non conservé en silver, jamais affiché
`verified_purchase`	Achat vérifié	Facultatif : variable descriptive, sans valeur de garantie de qualité
`helpful_vote`	Nombre de votes « utile »	Facultatif : variable descriptive
`asin`	Référence de variante	Écarté : à ne pas confondre avec `parent_asin`
`images`	Liste d'images	Écarté : pas de traitement d'images

Profil des données

Le fichier complet compte 2 105 948 avis uniques sur 94 319 produits, conformes aux ordres de grandeur publiés (environ 2,1 millions d'avis et 94 300 produits).

Mesure	Valeur
Lignes lues	2 128 605

Mesure	Valeur
Lignes rejetées (JSON, produit, note, date ou texte invalide)	0
Doublons supprimés	22 657 (1,1 %)
Avis uniques valides	2 105 948 (taux de conservation 98,9 %)
Produits (`parent_asin`)	94 319
Variantes (`asin`)	104 237
Période couverte	du 23/10/2000 au 12/09/2023
Unité du timestamp	millisecondes (100 % des lignes)
Produits ayant au moins 20 avis	14 526 (15,4 % des produits)
Avis couverts par ces produits	1 803 297 (85,6 % des avis)
Produit le plus commenté	B0B3DB5HTC : 11 906 avis
Mots par avis (titre + texte, avant nettoyage)	médiane 20, moyenne 35,6



profil_dataset.json · exécution complète du 01/11/2026 sur Appliances.jsonl.gz

Une note moyenne sera donc presque toujours élevée : la restitution montrera aussi la répartition des classes et l'effectif de chaque produit.

Mesures faites le 01/11/2026 avec explorer_dataset.py sur le fichier complet. Détail dans profil_dataset.json ; échantillon de contrôle de 5 avis (graine 42) dans echantillon_temoin.json.

Décisions de cadrage

Le « document » du TF-IDF est l'ensemble des avis d'un produit, et le travail démarre sur un lot stable de 5 % des produits.

Sujet	Décision	Raison
Clé produit	`parent_asin`	Regroupe les variantes d'un même produit (104 237 `asin` pour 94 319 produits)
Document TF-IDF	Ensemble des avis nettoyés d'un produit, identique dans MR1 et MR2	Un avis seul (médiane de 20 mots) est trop court pour un TF-IDF stable
Texte analysé	`title` + `text`	Le titre résume souvent l'aspect principal de l'avis
Dédoublonnage	Empreinte blake2b 64 bits de `user_id` + `parent_asin` + `timestamp` + texte	22 657 doublons mesurés ; probabilité de collision d'environ 10^{-7} pour 2,1 M avis
Anonymisation	`user_id` non conservé en silver, remplacé par la clé technique `review_key`	Exigence NF05 (sécurité des données)
Date	Timestamp en millisecondes converti en mois AAAA-MM, en UTC	Granularité de MR3
Lots de travail	Produits choisis par `md5(parent_asin)` : 5 % pour le développement, 20 % pour la validation, 100 % si les ressources le permettent	Sélection stable et reproductible, sans le biais d'ordre des premières lignes
Seuil d'affichage	20 avis minimum par produit, paramétrable ; appliqué à la restitution, pas aux calculs	Garde 85,6 % des avis tout en évitant des classements non robustes
N pour MR2	Nombre de produits ayant au moins un document textuel valide, calculé par le préparateur et archivé dans `manifeste.json`	Un N faux rend l'IDF faux

Sujet	Décision	Raison
Règles NLP v1	Minuscules, accents et balises HTML retirés, stop words anglais, négations conservées, nombres purs supprimés, mots de 2 à 30 caractères, sans deep learning	Versionnées : toute modification impose de régénérer les sorties
Vocabulaire	« Termes caractéristiques » et « polarité de notation », jamais « sentiment »	Un TF-IDF élevé ne prouve pas une opinion

Risques et mesures

Le principal risque mesuré est le déséquilibre, à la fois des notes (79,6 % à 4–5 étoiles) et des produits (un seul produit concentre 11 906 avis).

Risque	Effet	Mesure prévue
Notes déséquilibrées (79,6 % à 4–5 étoiles)	Moyennes presque toujours élevées, peu discriminantes	Afficher la répartition des classes et les effectifs, pas seulement la moyenne
Skew : un produit a 11 906 avis	Un reducer reçoit beaucoup plus de données que les autres	Combiner dans MR1 et MR3, profilage des clés, décision motivée sur le Partitioner
Produits peu évalués (84,6 % ont moins de 20 avis)	TF-IDF instable, classements non robustes	Seuil d'affichage paramétrable et effectifs affichés
Textes courts (médiane de 20 mots)	Peu de termes par avis	Document = produit ; seuil de support
Doublons (1,1 %)	Avis comptés deux fois	Dédoublonnage par empreinte et journal des anomalies
Volume par rapport à la RAM du poste	Arrêt de l'ingestion ou des jobs	Lots déterministes de 5 % et 20 %, Hadoop pseudo-distribué
Compatibilité Hadoop / Iceberg	Échec de l'import en tables	Versions figées et test de bout en bout dès la semaine 2

Risque	Effet	Mesure prévue
Négation, sarcasme, polysémie	Interprétation abusive des termes	Négations conservées ; parler de « termes caractéristiques »
Biais du corpus Amazon	Généralisation invalide	Conclusions limitées à *Appliances*, de 2000 à 2023
Données personnelles (`user_id`)	Risque de confidentialité	Non conservé en silver, jamais affiché ni exporté